

## ANÁLISE PREDITIVA COM REDES NEURAIS CONVOLUCIONAIS PARA O GEOPROCESSAMENTO DE IMAGENS

Cavalcante, E. S.<sup>1</sup>, Sousa, M. A.<sup>1</sup>

<sup>1</sup>Escola Politécnica e de Artes

Pontifícia Universidade Católica de Goiás

Goiânia-GO-Brasil

**Abstract** – This article presents the development of a Convolutional Neural Network (CNN), which is a type of Artificial Neural Network, with the objective of executing image geoprocessing predictions, based on input data. The system allows the analysis of inputs and results in an output value characterized by the value of the prediction, making possible the predictability of future scenarios. A system was developed based on the developed techniques, obtained through research, to implement the prediction of image assertiveness by the applied training. The performance of the developed system was verified with values obtained through a hypothetical scenario. The results are presented and discussed. In this context, this work presents a study of the application of these techniques in the decision support process to improve the control of soybean plantations.

**Keywords** – Convolutional Neural Network, Images, Geoprocessing.

**Resumo** – Este artigo apresenta o desenvolvimento de uma Rede Neural Convolucional (RNC), que é um tipo de Rede Neural Artificial, com o objetivo de executar processos de geoprocessamento, com destaque para a classificação de imagens de vegetação na produção agrícola. O sistema permite a análise de *inputs* e resulta em um valor de saída caracterizado pelo valor da predição, tornando possível a previsibilidade de cenários futuros. Foi desenvolvido um sistema baseado nas técnicas desenvolvidas, obtidas através de pesquisas, para implementar a previsão da assertividade na classificação de imagens de acordo com o treinamento aplicado. O desempenho do sistema desenvolvido é averiguado com valores obtidos por meio de um cenário hipotético. Os resultados são apresentados e discutidos. Nesse contexto, este trabalho apresenta um estudo da aplicação destas técnicas no processo de apoio à decisão para melhoria do controle da plantação de soja.

**Palavras-chave** – Rede Neural Convolucional, Imagens, Geoprocessamento.

### 1. Introdução

As pragas em lavouras causam prejuízos na agricultura e o manejo adequado é essencial. O controle dependente da identificação, pois é a partir dela que o manejo é feito. A identificação é feita visualmente, baseando-se nas características da praga. Devido à dificuldade da

identificação, esse processo é realizado principalmente por profissionais especializados na área, o que acarreta a concentração do conhecimento [1][2].

Técnicas de Inteligência Artificial (IA) vêm se destacando como ferramenta promissora na análise e classificação de imagens de geoprocessamento [3]. Dentre as várias técnicas de IA existe uma área de pesquisa chamada aprendizagem de máquina, com destaque para as Redes Neurais Artificiais (RNA), que visa fazer uma máquina (ou algoritmo) detectar e extrapolar novos padrões, com a capacidade de adaptação às novas circunstâncias [4].

A Rede Neural Convolucional (RNC) é uma das ferramentas usadas na aprendizagem de máquina, com ênfase na análise de imagem. O reconhecimento de objetos em imagens está se tornando cada vez mais fácil para os computadores, devido aos avanços em estudos de visão computacional que utilizam redes neurais de aprendizagem profunda. Essas redes tiveram grandes avanços a partir de 2012 e vêm sendo usadas em diversos problemas de classificações que envolvem imagens [5]. No contexto de classificação de imagens de produção agrícola, a rede pode estimar se uma imagem é de uma folha de soja saudável ou não, a partir de *features* como cor, formato e tamanho das folhas.

Neste trabalho, destacamos: as técnicas de inteligência artificial e os processos de aprendizagem de sistemas especialistas baseados em IA; os principais elementos das RNCs, bem como as suas aplicações, vantagens e desvantagens; detalhamos o protótipo do sistema desenvolvido, com destaque para o processo de implementação computacional; e mostramos os resultados mais relevantes das simulações computacionais.

## **2. Materiais e Métodos**

O projeto desenvolvido nesse trabalho está dividido em três etapas: estudo sobre técnicas de IA, ou seja, quais metodologias e parâmetros a serem utilizados para o treinamento da RNC; seguido de um treinamento no Orange [6], conforme a Figura 1, para definir qual técnica de análise de imagens seguir; e, por último, desenvolver um programa de reconhecimento de imagens na linguagem Python [7].

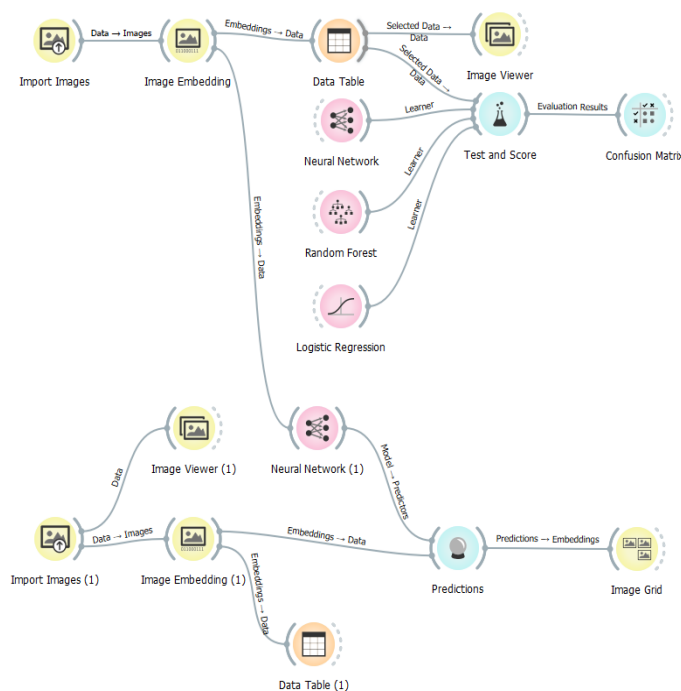


Figura 1 – Escolha do método RNC feita no Orange [8], autoria própria.

Dentre diversas linguagens de programação voltadas para o desenvolvimento de uma IA, foi escolhido o Python pelas seguintes características [7]. A rede neural convolucional é desenvolvida para auxiliar no processo de tomada de decisão em cenário de controle de pragas em plantação de soja. A partir da análise das imagens coletadas e comparadas com o *database*, o sistema deve ser capaz de dizer se uma imagem de um quadrante coletado da plantação está com suas folhas saudáveis ou com doença (diabrotica speciosa, por exemplo) [8], marcas de furos deixadas por insetos nas folhas.

A base de dados utilizada possui 3.102 fotos de folhas de sojas de diferentes perspectivas, divididas em dois grupos:

- Imagens de treinamento e validação: com 2.800 imagens, sendo que 2.000 possuem a doença confirmada e 800 são saudáveis, também confirmadas pelo fornecedor da base de dados [8].
- Imagens de teste: composto por 96 imagens de folhas de soja potencialmente saudáveis e outras 206 de folhas de soja potencialmente doentes.

Neste projeto, as principais bibliotecas utilizadas para realização do treinamento da RNC são: Keras [9], juntamente com o Tensorflow [10], para criação e treinamento de redes neurais; Numpy [11], que suporta o processamento de grandes, multidimensionais arranjos e matrizes, juntamente com uma grande coleção de funções matemáticas de alto nível para operar sobre estas matrizes; e por fim a biblioteca Matplotlib [12], que serve para criação de gráficos e visualizações de dados em geral.

Devido à complexidade das operações de convolução e a intrincada interconexão dos neurônios, as redes neurais convolucionais tendem a apresentar alto custo computacional e baixa velocidade de treinamento. A fim de otimizar a operação dessas redes, as operações de convolução são, comumente, executadas em hardware especializado como em unidades de processamento gráfico (GPU). Neste trabalho, foi utilizada uma AMD Radeon Vega 8 Graphics.

Um Cenário de Aplicação foi desenvolvido. A Figura 2 descreve um possível fluxograma do processo de tomada de decisão no controle da doença após as análises das imagens. O processo de tomada de decisão pode ser realimentado com informações que podem ser coletadas com mais imagens obtidas a partir do sensoriamento remoto. Logo, quanto mais levantamentos forem feitos na plantação de soja, mais imagens diferentes irão para o banco de dados, assim a RNC será alimentada constantemente e terá uma taxa de assertividade ainda melhor nas próximas análises de estado da plantação.

O sistema de predição desenvolvido neste trabalho pode ser inserido neste cenário como ferramenta de apoio no processo de tomada de decisão em conjunto com o sensoriamento remoto. A proposta é avaliar o desempenho e a validade do sistema de predição em estimar as necessidades de uma plantação de soja caso ela esteja com alguma doença de difícil identificação a “olho nu” ou em uma área muito pequena, mas que possa se alastrar para setores maiores. A Figura 3 apresenta o processo de treinamento supervisionado para o sistema de predição proposto neste trabalho, com aplicação na determinação do estado de saúde de uma plantação de soja.

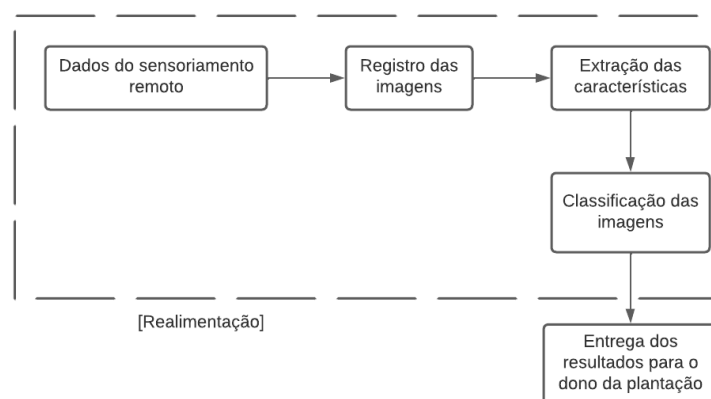


Figura 2 – Fluxograma do processo de geoprocessamento de imagens, autoria própria.

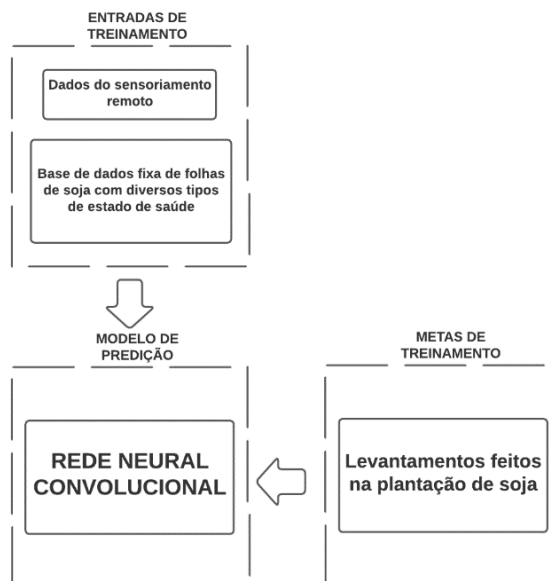


Figura 3 – Treinamento do sistema de predição para a determinação do estado de saúde de uma plantação de soja, autoria própria.

Após a aquisição das imagens ter sido realizada, algumas imagens podem apresentar imperfeições, e então o pré-processamento é utilizado a fim de amenizar problemas de ruído, contraste ou brilho inadequado, entre outras.

### 3. Resultados e Discussão

Nesta seção são descritos alguns resultados preliminares para as técnicas de configuração, treinamento e aplicação da IA no geoprocessamento de imagens. A RNC foi escolhida perante as alternativas, Floresta Aleatória e Regressão Logística, pois teve uma taxa de precisão e acurácia melhor, de 98,2%, conforme observado na Tabela 1. A tabela mostra, respectivamente, o tipo de modelo avaliado; de 0, mínimo e 1, máximo, a acurácia, precisão do subconjunto, média harmônica de precisão, precisão total e a capacidade do classificador de encontrar todas as amostras positivas.

Tabela 1 - Treinamento realizado no Orange, autoria própria.

| Modelo                      | AUC          | CA           | F1           | Precisão     | Memória      |
|-----------------------------|--------------|--------------|--------------|--------------|--------------|
| Floresta Aleatória          | 0.942        | 0.868        | 0.866        | 0.866        | 0.868        |
| <b>Neural Network (RNC)</b> | <b>0.982</b> | <b>0.940</b> | <b>0.940</b> | <b>0.941</b> | <b>0.940</b> |
| Regressão Logística         | 0.979        | 0.935        | 0.935        | 0.936        | 0.935        |

O resultado do treinamento da RNC, com a base de dados das folhas saudáveis e doentes, pode ser conferido na Tabela 2. O objetivo foi identificar a melhor configuração da RNC para o processo de predição, com destaque para o número de *epoch*. A melhor média para a acurácia

alcançada foi aquela com 250 *epochs*. No entanto, a melhor validação aconteceu com 300 *epochs*.

Tabela 2 – Treinamento da RNC x Número de *epochs*, autoria própria.

Escolha do número de *epochs* baseadas nas médias de desempenho

| Número de Epochs | Acurácia (Treino) | Perda (Treino) | Acurácia (Validação) | Perda (Validação) |
|------------------|-------------------|----------------|----------------------|-------------------|
| 50               | 0,7782            | 0,4851         | 0,6580               | 0,6566            |
| 100              | 0,7972            | 0,4498         | 0,6221               | 0,7325            |
| 150              | 0,8167            | 0,4176         | 0,6552               | 0,7345            |
| 200              | 0,8375            | 0,3773         | 0,6455               | 0,8821            |
| 250              | 0,8961            | 0,2633         | 0,6867               | 1,1499            |
| 300              | 0,8817            | 0,2864         | 0,6870               | 1,0147            |

Observação: valores médios arredondados para 4 casas decimais.

A evolução do processo de treinamento e validação da RNC com 300 *epochs* pode ser conferido no Figura 4. A Perda diminui mais que em 250 *epochs* até que os valores de Treino e Validação sejam mais parecidos em 300 *epochs*.

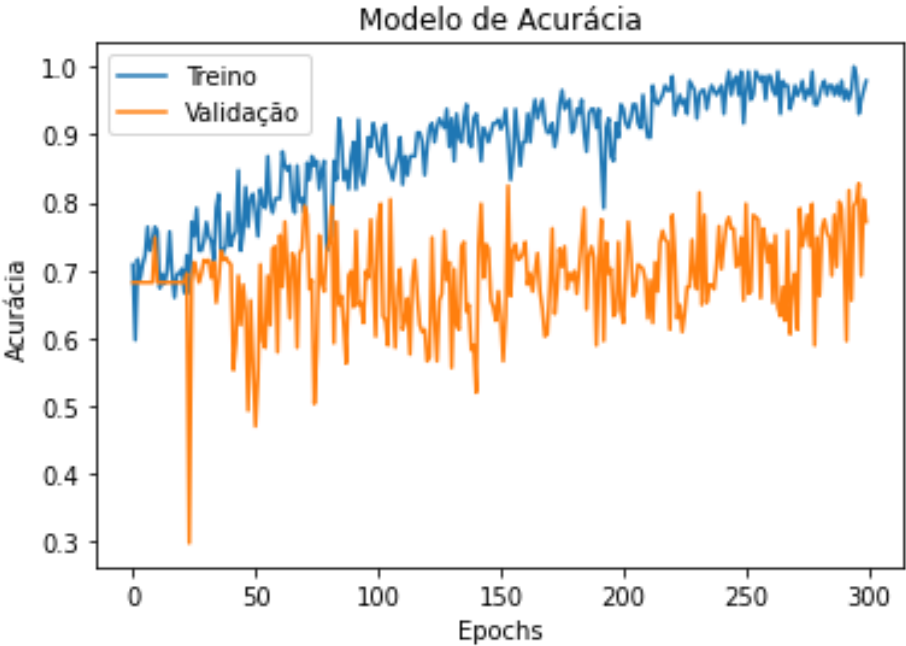


Figura 4– Comparativo de valores verdadeiros em relação a predição, autoria própria.

Para que o modelo não alcance um *overfitting*, ou seja, quando um modelo estatístico se ajusta muito bem ao conjunto de dados observado, mas se mostra ineficaz para prever novos resultados, é coerente a procura por pelo menos dois dos principais critérios de parada do processo de treinamento: número máximo de iterações (*epoch*) e erro mínimo alcançado. Para a minimização do erro, uma alternativa é adquirir mais dados com o intuito de equilibrar a quantidade de parâmetros *versus* a quantidade de instâncias de treinamento.

A RNC configurada e treinada pode, então, ser utilizada na predição para auxiliar no processo de tomada de decisão. A Figura 5 apresenta um exemplo de resultado preliminar da predição da RNC para uma entrada com seis imagens de teste que poderiam ter sido obtidas por um processo de sensoriamento remoto e que necessitam ser analisadas. Para simular esse cenário, neste estudo foram separadas seis imagens aleatórias da base de dados, integrantes do grupo de imagens de teste. Para esse cenário, a RNC implementada conseguiu classificar as imagens com 100% de acurácia. As imagens de saída classificadas como “Diabrotica” são realmente “Doentes”, enquanto as imagens de saída classificadas como “Healthy” são realmente “Saudáveis”, conforme registrado no grupo de imagens de teste, da base de dados utilizada nesse trabalho.

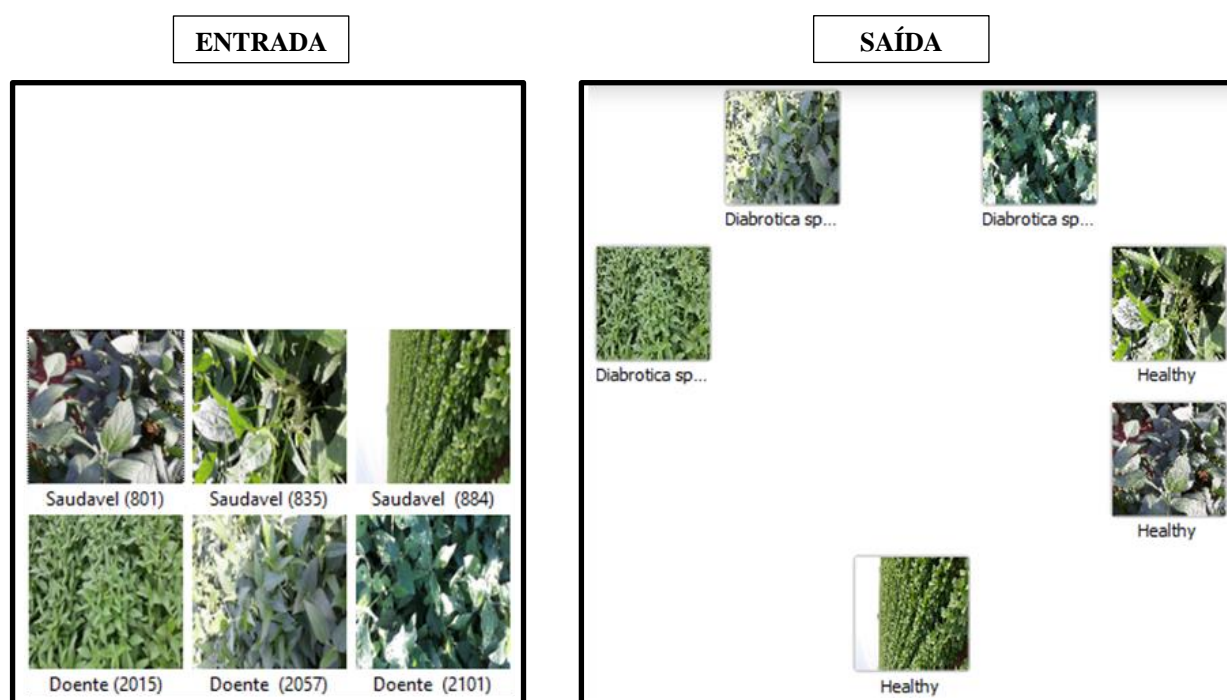


Figura 5 – Resultado do treinamento da RNC, autoria própria.

Nota-se que algumas imagens ficam mais próximas da linha de tendência da classificação oposta do que outras. Este acontecimento pode ser explicado pelo seguinte motivo: os erros cometidos geralmente estão associados a probabilidades de classificação mais dispersas, isso indica uma incerteza do modelo frente às imagens mal classificadas

Com o objetivo de melhorar o processo de tomada de decisão do sistema proposto, foi realizado um ajuste nos neurônios utilizados no RNC, neste caso reescalar todas as imagens, de treino e teste, para as mesmas dimensões foram de boa valia, pois a quantidade de pixels utilizados por imagens torna-se mais padrão, logo mais fica mais fácil o comparativo entre as imagens.

#### **4. Conclusão**

Com a tecnologia atual, o volume de produção de dados aumenta, tornando difícil a extração de informações. A IA entra como alternativa para resolver esse problema, automatizando os processos de aplicação e tomada de decisões e controle.

A RNC é de suma importância, pois pode ser utilizada na predição de futuros cenários de calamidades nas plantações de soja.

Os resultados são promissores, uma vez que a RNC desenvolvida classifica as imagens das folhas de soja com maior precisão e assertividade.

Para trabalhos futuros, vislumbra-se a implementação completa de uma Interface de Usuário e avaliar o desempenho do sistema de predição desenvolvido em diversos cenários:

- Estudo de campo, com coleta de dados reais, acrescida de uma base de dados robusta obtidas a partir do sensoriamento remoto realizado;
- Avaliar a utilização do aprendizado por reforço, já que existe uma base de dados para treinamento da RNC, porém, pode não haver classificação prévia de novas imagens que podem estar sendo captadas, por exemplo, em tempo real.
- Aplicação em diferentes plantações, com diferentes tipos de estágio da planta, doenças ou outros agravantes;

#### **5. Referências Bibliográficas**

1. VAZ, Maria Salete Marcon Gomes; BRITTO JUNIOR, Alceu de Souza; JORIS, Hélio Antônio Wood. MÉTODO DE CLASSIFICAÇÃO DE PRAGAS POR MEIO DE REDE NEURAL CONVOLUCIONAL PROFUNDA. Programa de Pós-Graduação Computação Aplicada, Brasil, 19 nov. 2018. Universidade Estadual de Ponta Grossa, p. 7-8. Disponível em: <http://tede2.uepg.br/jspui/handle/prefix/2747>. Acesso em: 30 out. 2022.
2. FERREIRA, Laerte Guimarães; FERREIRA, Nilson Clementino; FERREIRA, Manuel Eduardo. Sensoriamento remoto da vegetação: evolução e estado-da-arte. *Acta Scientiarum. Biological Sciences*, v. 30, n. 4, p. 379-390, 2008.
3. K. Faceli, A.C. Lorena, J. Gama, A.C.P.L.F Carvalho. *Inteligência Artificial - Uma Abordagem de Aprendizado de Máquina*. LTC, 2011.



4. S. RUSSELL and P. NORVIG, Artificial Intelligence: A Modern Approach, 4th ed. Upper Saddle River, NJ, USA: Prentice Hall, 2009.
5. SILVA, Rodrigo Emerson Valentim da. Um estudo comparativo entre redes neurais convolucionais para a classificação de imagens. 2018.
6. University of Ljubljana. Orange Data Mining (.exe). Disponível em: <<https://orangedatamining.com/>>. Acesso em: 30 out. 2022.
7. PYTHON SOFTWARE FOUNDATION. Python Language Site: Documentation, 2020. Página de documentação. Disponível em: <<https://www.python.org/doc/>>. Acesso em: 14 de nov. de 2022.
8. Mignoni, Maria Eloisa (2021), “Images of Soybean Leaves”, Mendeley Data, V1, doi: 10.17632/bycbh73438.1
9. KERAS. Keras: The Python deep learning API. Disponível em: <<https://keras.io/>>. Acesso em: 14 nov. 2022
10. TensorFlow: Large-scale machine learning on heterogeneous systems, 2015. Disponível em: <<https://tensorflow.org>>. Acesso em: 14 nov. 2022
11. Numpy: the fundamental package for scientific computing with Python, 2005. Disponível em: <<https://numpy.org>>. Acesso em: 14 nov. 2022.
12. Matplotlib: Visualization with Python, 2012. Disponível em: <<https://matplotlib.org>>. Acesso em: 14 nov. 2022.